

Flexible Pattern Matching

January 20, 2016

Testsätze und -pattern sowie Hilfsfunktion um Treffer in diesen zu rendern

```
In [1]: from IPython.display import display_html

tests = [("Ich bin ein Moofoo der in Barfoo lebt.", "foo"),
         ("And the magician said: 'abracadabracadabra, simsalabim!'", "abracadabra"),
         ("CPM_annual_conference_announce", "announce"),
         ("I have an overlapping patpattpattern!", "pattern")]

def print_highlighted_tests(search_fn):
    out = []
    for text, pattern in tests:
        start_idx = search_fn(text, pattern)
        text = list(text)
        for idx in start_idx:
            text[idx] = '<strong>' + text[idx]
            end_idx = idx + len(pattern) - 1
            text[end_idx] += '</strong>'
        display_html("".join(text), raw=True)
```

1 Simple Pattern Matching

- eine Schleife, die über den Text itertiert (kann beendet werden, sobald der restliche Text kürzer wäre als das Pattern selbst)
- eine zweite Schleife, die an jeder Position des Textes über die nächsten Buchstaben und das Pattern iteriert und abbricht, sobald ein Buchstabe im Pattern nicht mit dem aktuellen Buchstaben im Text übereinstimmt
- wenn die zweite Schleife komplett durchlaufen wurde, wurde ein Match gefunden

```
In [2]: def simple_search(text, pattern):
        # Walk forwards through the text
        for text_idx in range(len(text) - len(pattern) + 1):
            # Walk forwards through the pattern
            for pat_idx, char in enumerate(pattern):
                # Does the text match the pattern?
                if char != text[text_idx + pat_idx]:
                    # Nay, go to the next character in the text
                    # and try the pattern again
                    break
            else:
                # Yay, we got a match! (Because all pattern symbols matched)
                yield text_idx
```

```
# PROBLEM: In case of a mismatch, we always start reading the full pattern again,
#           just for the next position in the text -> Inefficient!

print_highlighted_tests(simple_search)
```

2 Knuth-Morris-Pratt

- das selbe Prinzip wie beim Simple Pattern Matching
- das Pattern wird jedoch bei einem Mismatch von Buchstaben “weiter nach vorne geschoben”
- hierbei hilft eine Prefix-Tabelle (auch Next-Funktion) die die “Verschiebepositionen” speichert. (Die Verschiebeposition ist die Länge des längsten Suffix des Teils des Patterns der gefunden wurde, der gleichzeitig Präfix des gesamten Patterns ist)

```
In [3]: def get_prefix_table(pattern):
        i, j = 0, -1
        prefix_table = [-1] * (len(pattern) + 1)
        while i < len(pattern):
            while j >= 0 and pattern[j] != pattern[i]:
                j = prefix_table[j]
            i += 1
            j += 1
            if i == len(pattern):
                prefix_table[i] = j
            elif pattern[i] != pattern[j]:
                prefix_table[i] = j
            else:
                prefix_table[i] = prefix_table[j]
        return prefix_table

        print(get_prefix_table('abracadabra'))
```

```
[-1, 0, 0, -1, 1, -1, 1, -1, 0, 0, -1, 4]
```

Table 1: Präfix-Tabelle für das Pattern abracadabra

0	1	2	3	4	5	6	7	8	9	10	match
a	b	r	a	c	a	d	a	b	r	a	
-1	0	0	-1	1	-1	1	-1	0	0	-1	4

```
In [4]: def kmp_search(text, pattern):
        prefix_table = get_prefix_table(pattern)
        text_idx, pat_idx = 0, 0
        while text_idx < len(text):
            while pat_idx >= 0 and text[text_idx] != pattern[pat_idx]:
                pat_idx = prefix_table[pat_idx]
            text_idx += 1
            pat_idx += 1
            if pat_idx == len(pattern):
                yield text_idx - len(pattern)
                pat_idx = prefix_table[pat_idx]

        print_highlighted_tests(kmp_search)
```

3 Shift-And

- Automat wird mit Bitmasken repräsentiert
- Bitmasken für jeden Buchstaben im Pattern erstellen (alle anderen Buchstaben haben 0-Vektor als Bitmaske)
- Vektor der einen Automaten repräsentiert, dessen Anfangszustand immer aktiv ist, wird durch Shift-Operationen “durchlaufen” und mit der Bitmaske des aktuell gelesenen Buchstabens im Text “verundet”
- wenn der letzte Zustand des Automaten aktiv ist, wurde das Pattern gefunden
- Endianness der Vektoren ist zu beachten! (immer Big Endian?)

```
In [5]: from bitstring import BitArray
        from collections import defaultdict

        def get_bit_table(pattern):
            alphabet = set(pattern)
            # Every entry represents the *reversed* pattern, with a 1
            # at the positions with the character
            table = {char: BitArray('0b' + ''.join('1' if c == char else '0'
                                                    for c in reversed(pattern)))
                    for char in alphabet}
            return table

        [get_bit_table('foo'), get_bit_table('abracadabra')]

Out[5]: [{'f': BitArray('0b001'), 'o': BitArray('0b110')},
         {'a': BitArray('0b10010101001'),
          'b': BitArray('0b00100000010'),
          'c': BitArray('0b00000010000'),
          'd': BitArray('0b00001000000'),
          'r': BitArray('0b01000000100')}]
```

Table 2: Bitmasken-Tabelle für das Pattern abracadabra

letter											
a	1	0	0	1	0	1	0	1	0	0	1
b	0	0	1	0	0	0	0	0	0	1	0
r	0	1	0	0	0	0	0	0	1	0	0
c	0	0	0	0	0	0	1	0	0	0	0
d	0	0	0	0	1	0	0	0	0	0	0
	0	0	0	0	0	0	0	0	0	0	0

```
In [6]: def shift_and_search(text, pattern):
        m = len(pattern)
        bit_table = get_bit_table(pattern)
        empty_vec = BitArray(length=m)
        # Vector that represents a full match on the pattern
        found_vec = BitArray('0b1' + '0'*(m-1)) # '1000...'
        # Vector that adds a 'empty_word' transition on the first state
        # to itself
        init_vec = BitArray('0b' + '0'*(m-1) + '1') # '...0001'

        # In the beginning, all states in the NFA are inactive
```

```

    automaton = BitArray(length=m) # '0000...'
    for text_idx, char in enumerate(text):
        char_vec = bit_table.get(char, empty_vec)
        automaton <<= 1 # shift/advance in the NFA
        automaton |= init_vec # activate the first state
        automaton &= char_vec # and/activate the character states
        if automaton & found_vec != empty_vec: # Is the final state active?
            yield text_idx - m + 1

print_highlighted_tests(shift_and_search)

```

4 Shift-Or

- gleiches Konzept wie beim Shift-And Verfahren
- hier repräsentieren 0en aktive und 1en inaktive Zustände, so kann der Schritt des “aktiv machens” des ersten Zustands des Automaten gespart werden, da beim shift automatisch eine neue 0 (aktiver Zustand) hinzugefügt wird
- alle Bitvektoren sind hier natürlich invertiert

```

In [7]: def shift_or_search(text, pattern):
    m = len(pattern)
    empty_vec = BitArray('0b' + '1'*m) # '1111...'

    # Vector that represents a full match on the pattern
    found_vec = BitArray('0b0' + '1'*(m-1)) # '0111...'

    # XORing with an all-one array of same length creates the complement
    bit_table = {char: vec ^ empty_vec
                  for char, vec in get_bit_table(pattern).items()}

    # In the beginning, all states in the NFA are inactive
    automaton = BitArray('0b' + '1'*m) # '1111...'
    for text_idx, char in enumerate(text):
        automaton = (automaton << 1 | bit_table.get(char, empty_vec))
        if (automaton | found_vec) != empty_vec:
            yield text_idx - m + 1

print_highlighted_tests(shift_or_search)

```

5 Boyer-Moore

- Pattern wird wie zuvor von links nach rechts durch den Text geschoben, jedoch wird nun das Pattern von rechts nach links durchlaufen (in natürlichen Sprachen wird so üblicherweise früher ein Mismatch gefunden und das Pattern kann schneller verschoben werden)
- für die Verschiebung werden zwei Heuristiken angewandt
 - **Bad-Character Heuristik** bei einem Mismatch kann das Pattern soweit verschoben werden, dass der aktuell im Text gelesene Buchstabe mit dem letzten vorkommen dieses Buchstabens im Pattern aligniert ist, wenn dieser Buchstabe gar nicht im Pattern vorkommt, kann das Pattern um seine ganze Länge verschoben werden
 - **Good-Suffix Heuristik** Wenn das bis zum Mismatch gelesene Suffix des Patterns nochmals Infix des Patterns ist, kann das Pattern soweit verschoben werden, bis der gelesene Teil mit diesem Infix aligniert ist, kommt dieses Suffix kein zweites mal im Pattern vor, kann das Pattern um seine ganze Länge verschoben werden

- es wird immer die maximale Verschiebung die sich durch diese Heristiken ergeben angewandt

6 Horspool

- Wie bei Boyer-Moore wird der Text von links nach rechts, das Pattern aber von rechts nach links durchlaufen
- sobald ein Mismatch erreicht wird, wird das Pattern soweit verschoben, dass das gerade gelesene Zeichen im Text mit dem letzten

```
In [8]: def get_horspool_table(pattern):
        return {char: len(pattern)-j-1
                for j, char in enumerate(pattern[::-1])}

        get_horspool_table('announce')
```

```
Out[8]: {'a': 7, 'c': 1, 'n': 2, 'o': 4, 'u': 3}
```

```
In [9]: def horspool_search(text, pattern):
        n = len(text) - 1
        m = len(pattern) - 1
        table = get_horspool_table(pattern)
        pos = -1
        # Walk through text from left to right
        while pos <= n - m:
            j = m
            # Walk through pattern from right to left
            while j >= 0 and text[pos + j] == pattern[j]:
                j -= 1
            # Did we get through the whole pattern?
            if j == -1:
                yield pos
            current_char = text[pos+m]
            # What's the index of the character in the pattern?
            # If the character is not in the table, use the pattern length
            last_idx_in_pattern = table.get(current_char, m)
            pos += last_idx_in_pattern

        print_highlighted_tests(horspool_search)
```

7 Faktorbasierte Suche

TODO: Allgemeine Idee/Ansatz

7.1 Backward Nondeterministic DAWG Matching

Ähnlich wie Shift/And, in diesem Fall wird aber nach Faktoren/Infixen des Pattern gesucht um so die Verschiebung zu maximieren.

```
In [16]: # TODO: Broken!
        def bndm_search(text, pattern):
            bit_table = get_bit_table(pattern)
            empty_vec = BitArray(length=len(pattern))
            found_vec = BitArray('0b1' + '0'*(len(pattern)-1))
            n = len(text) - 1
```

```

    m = len(pattern) - 1
    pos = -1
    while pos <= n - m:
        j = m
        last = m
        D = BitArray('0b' + '1'*(m+1))
        while D != empty_vec:
            char_vec = bit_table.get(text[pos+j], empty_vec)
            D &= char_vec
            j -= 1
            if D & found_vec != empty_vec:
                if j > -1:
                    last = j
                else:
                    yield pos + 1
            D <<= 1
            pos += last

print_highlighted_tests(bndm_search)

-----

KeyboardInterrupt                                Traceback (most recent call last)

<ipython-input-16-8e7192b15fa7> in <module>()
    23         pos += last
    24
--> 25 print_highlighted_tests(bndm_search)

<ipython-input-1-12c9f611e47d> in print_highlighted_tests(search_fn)
    11         start_idxs = search_fn(text, pattern)
    12         text = list(text)
--> 13         for idx in start_idxs:
    14             text[idx] = '<strong>' + text[idx]
    15             end_idx = idx+len(pattern)-1

<ipython-input-16-8e7192b15fa7> in bndm_search(text, pattern)
    15         D &= char_vec
    16         j -= 1
--> 17         if D & found_vec != empty_vec:
    18             if j > -1:
    19                 last = j

/home/jojo/.envs/nlp/lib/python3.4/site-packages/bitstring.py in __iand__(self, bs)
1078         raise ValueError("Bitstrings must have the same length "
1079                             "for & operator.")
-> 1080         s = self._copy()
1081         s._iand(bs)
1082         return s

```

```

/home/jojo/.envs/nlp/lib/python3.4/site-packages/bitstring.py in _copy(self)
1981     """Create and return a new copy of the Bits (always in memory)."""
1982     s_copy = self.__class__()
-> 1983     s_copy._setbytes_unsafe(self._datastore.getbyteslice(0, self._datastore.bytelength),
1984                             self.len, self._offset)
1985     return s_copy

/home/jojo/.envs/nlp/lib/python3.4/site-packages/bitstring.py in getbyteslice(self, start, end)
157     def getbyteslice(self, start, end):
158         """Direct access to byte data."""
--> 159         c = self._rawarray[start:end]
160         return c
161

```

KeyboardInterrupt:

7.2 Backward Oracle Matching

TODO: Erklärung

```

In [11]: # TODO: Simple Trie implementation

         # TODO: Function to generate oracle

```